


**UNIVERSIDAD NACIONAL DEL ALTIPLANO**

Facultad de Ingeniería Estadística e Informática

Escuela Profesional de Ingeniería Estadística e Informática

**INFORME TÉCNICO**

# Predicción de la demanda de inmunizaciones en EsSalud

Modelos de aprendizaje automático para regresión y clasificación

**Autor:** David León Callohuanca Condori

**Fuente:** Inmunización EsSalud (2015–2022)

**Cobertura:** Registros nacionales y evaluación geográfica en Puno

Puno – Perú

2026

**Resumen**

Este informe presenta el análisis exploratorio y el modelado predictivo de la demanda de inmunizaciones registrada por EsSalud entre 2015 y 2022. Se describen las variables, la fuente, la preparación de los datos, los resultados exploratorios y la evaluación de modelos.

Se desarrollaron dos tareas: regresión, con la variable $\log(1 + \texttt{total})$, y clasificación en niveles de demanda Baja, Media y Alta. XGBRegressor obtuvo $R^2 = 0{,}5021$ y RMSE=0.934; LGBMClassifier alcanzó Balanced Accuracy=0.6218 y F1=0.6162. También se evaluó el desempeño en los registros de Puno.

El código y los archivos reproducibles se alojan en GitHub. Este informe presenta la metodología y los resultados, sin incluir el código de programación.

**Palabras clave:** inmunizaciones, demanda, EsSalud, aprendizaje automático, LazyPredict, regresión, clasificación, XGBoost, LightGBM, Puno.

# Índice

**1. Planteamiento del problema** **1**

1.1. Pregunta de investigación . . . . . 1

1.2. Objetivo general . . . . . 1

1.3. Objetivos específicos . . . . . 1

**2. Variables de estudio** **1**

**3. Técnica e instrumentos** **2**

3.1. Técnica . . . . . 2

3.2. Instrumentos . . . . . 2

**4. Recolección de datos** **3**

**5. Tabulación** **3**

5.1. Registros y dosis por año . . . . . 3

5.2. Dosis por mes . . . . . 4

**6. Limpieza y diagnóstico de datos faltantes** **4**

6.1. Faltantes explícitos . . . . . 4

6.2. Faltantes implícitos en el panel centro–mes . . . . . 5

6.3. Consideración de los mecanismos MCAR, MAR y MNAR . . . . . 5

6.4. Operaciones de limpieza . . . . . 5

**7. Imputación** **6**

**8. Construcción de variables derivadas** **6**

**9. Análisis exploratorio de datos (EDA)** **6**

9.1. Distribución de la variable `total` . . . . . 6

9.2. Evolución anual y estacionalidad mensual . . . . . 7

9.3. Distribución conjunta por año y mes . . . . . 7

9.4. Dosis por familia de vacuna y red prestacional . . . . . 8

9.5. Distribución de la demanda por familia . . . . . 8

9.6. Comparación entre Puno y el resto del país . . . . . 9

9.7. Asociación Eta cuadrado entre predictoras y demanda . . . . . 10

**10. Definición de las variables objetivo** **10**

10.1. Variable objetivo de regresión . . . . . 10

10.2. Variable objetivo de clasificación . . . . . 10

**11. Diseño de modelado y partición de datos 11**

**12. Modelado con LazyPredict 12**

12.1. Comparación de modelos de regresión . . . . . 12

12.2. Comparación de modelos de clasificación . . . . . 13

**13. Evaluación y validación de los modelos seleccionados 14**

13.1. Validación del modelo de regresión (XGBRegressor) . . . . . 14

13.2. Validación del modelo de clasificación (LGBMClassifier) . . . . . 15

13.3. Importancia de variables mediante permutación . . . . . 16

**14. Discusión de resultados 17**

**15. Limitaciones del estudio 17**

**16. Conclusiones 17**

**17. Recomendaciones 18**

**18. Repositorio y reproducibilidad 18**

**Anexo: relación de productos gráficos 18**

# 1. Planteamiento del problema

EsSalud administra servicios de inmunización en centros asistenciales pertenecientes a distintas redes prestacionales. La cantidad de dosis registradas varía según el establecimiento, el tipo de vacuna y el periodo de aplicación. Esta variabilidad representa un desafío para la planificación de compras, almacenamiento, cadena de frío y asignación de personal.

La pandemia por COVID-19 constituye un contexto relevante para el periodo analizado, debido a que pudo alterar la continuidad de los servicios y los patrones habituales de vacunación. En consecuencia, una planificación basada únicamente en promedios generales podría no representar adecuadamente las diferencias entre centros asistenciales y familias de vacunas.

## 1.1. Pregunta de investigación

¿Qué modelos de aprendizaje automático presentan el mejor desempeño para predecir la cantidad de dosis registradas por centro asistencial, periodo y familia de vacuna, y cómo se comportan al evaluar su capacidad predictiva en los registros del departamento de Puno?

## 1.2. Objetivo general

Identificar y evaluar modelos de regresión y clasificación para la predicción de la demanda de inmunizaciones de EsSalud, mediante LazyPredict, considerando los registros nacionales del periodo 2015–2022 y una evaluación geográfica específica en Puno.

## 1.3. Objetivos específicos

1. Describir la estructura y las características de la base de datos.
2. Examinar la distribución de la demanda según año, mes, familia de vacuna y red prestacional.
3. Diagnosticar los valores faltantes explícitos e implícitos y documentar su tratamiento.
4. Construir las variables objetivo para regresión y clasificación.
5. Comparar algoritmos supervisados mediante LazyPredict.
6. Evaluar los modelos seleccionados en la prueba nacional y en los registros de Puno.

# 2. Variables de estudio

La unidad de análisis corresponde a un registro de demanda asociado a un centro asistencial, un periodo mensual y un servicio o tipo de vacuna. La variable `total` representa la cantidad registrada en la fuente para dicha combinación.

**Tabla 1:** Identificación de las variables del estudio

| Variable | Rol | Tipo | Descripción |
|---|---|---|---|
| `log_total` | Dependiente, regresión | Cuantitativa continua | Transformación $\log(1 + \texttt{total})$. |
| `nivel_demanda` | Dependiente, clasificación | Cualitativa ordinal | Categorías Baja, Media y Alta, construidas mediante terciles. |
| `Año` | Independiente | Cuantitativa discreta | Año del registro, 2015–2022. |
| `mes` | Independiente | Cuantitativa discreta | Mes calendario, de 1 a 12. |
| `covid` | Independiente | Dicotómica | 1 para 2020–2021 y 0 para los demás años. |
| `red_ses` | Independiente | Cualitativa nominal | Red prestacional del establecimiento. |
| `codcentro_ses` | Independiente | Cualitativa nominal | Código del centro asistencial. |
| `familia_vacuna` | Independiente | Cualitativa nominal | Agrupación de los tipos de vacuna. |
| `DEPARTAMENTO` | Auxiliar | Cualitativa nominal | Se utiliza para identificar y separar Puno. |

Las variables `Año`, `mes`, `covid`, `red_ses`, `codcentro_ses` y `familia_vacuna` constituyen el conjunto principal de predictoras descrito en el procedimiento. La variable `DEPARTAMENTO` se conserva para delimitar la evaluación geográfica y no debe confundirse con una predictora del modelo.

# 3. Técnica e instrumentos

## 3.1. Técnica

Se empleó el análisis documental de una base de datos secundaria de carácter administrativo. No se aplicaron encuestas ni mediciones directas a personas; se procesaron registros previamente recopilados por la entidad responsable de la información.

## 3.2. Instrumentos

Para el desarrollo del estudio se consideran los siguientes instrumentos y recursos:

- Base de datos de inmunizaciones de EsSalud en formato CSV o XLSX.
- Diccionario de datos para reconocer los campos y sus definiciones.
- Ficha de metadatos de la fuente.
- Ficha de registro y control de las variables utilizadas.

- Entorno de procesamiento Python y bibliotecas para manipulación, visualización y modelado estadístico.

El procesamiento computacional se implementó con Python y bibliotecas como pandas, NumPy, SciPy, Matplotlib, Seaborn, scikit-learn y LazyPredict. XGBoost y LightGBM se emplearon para los modelos correspondientes cuando estuvieron disponibles.

# 4. Recolección de datos

La información procede del conjunto de datos denominado *Inmunización EsSalud del 2015 al 2022*, publicado en la Plataforma Nacional de Datos Abiertos del Estado peruano. La base se obtuvo en formato tabular y se preparó para su análisis en Python.

La estructura de trabajo corresponde a un formato largo: cada fila representa una combinación de centro asistencial, periodo y servicio o tipo de vacuna. En la versión CSV se utilizan los campos existentes en la fuente.

**Tabla 2:** Ficha descriptiva de la fuente de datos

| **Característica** | **Descripción** |
|---|---|
| Nombre del conjunto | Inmunización EsSalud del 2015 al 2022 |
| Entidad de referencia | EsSalud |
| Portal de publicación | Plataforma Nacional de Datos Abiertos |
| Periodo analizado | 2015–2022 |
| Unidad de análisis | Registro centro–mes–servicio o vacuna |
| Variable de cantidad | `total` (Total de dosis: 18,421,716) |
| Cobertura | Registros nacionales; Puno se separa para evaluación geográfica |

Se trabajó con 614,465 registros y 14 variables. Los datos fueron depurados y se verificó que no existieran duplicados ni valores de `total` menores o iguales a cero.

# 5. Tabulación

La fuente presenta los datos en formato tabular. En esta etapa se elaboraron tablas de resumen para describir los registros y las dosis acumuladas por año y por mes. La tabulación permite reconocer la evolución temporal y los posibles patrones estacionales antes de iniciar el modelado.

## 5.1. Registros y dosis por año

Entre 2015 y 2019 se observa un comportamiento relativamente estable, con un promedio superior a 2.3 millones de dosis anuales. Durante 2020–2021 se identifica una reducción,

alcanzando 1,988,728 dosis en 2021 (10.80 % del total). Para 2022 se reporta una recuperación hasta 2,492,295 dosis (13.53 %).

**Tabla 3:** T01. Síntesis de la evolución anual de dosis

| Periodo | Resultado e interpretación |
|---|---|
| 2015–2019 | Comportamiento relativamente estable; promedio anual superior a 2.3 millones de dosis. |
| 2020–2021 | Disminución durante el contexto de pandemia; en 2021 se reportan 1,988,728 dosis. |
| 2022 | Recuperación hasta 2,492,295 dosis. |

### 5.2. Dosis por mes

La distribución mensual muestra diferencias en la cantidad acumulada de dosis. Junio concentra el 10.68 %, julio el 9.73 % y noviembre el 9.59 %. Por el contrario, abril registra el 5.84 % y marzo el 6.76 %. Estos resultados sugieren que la demanda no se distribuye uniformemente durante el año.

**Tabla 4:** T02. Participación de dosis en meses seleccionados

| Mes | Porcentaje de dosis |
|---|---|
| Junio | 10.68 % |
| Julio | 9.73 % |
| Noviembre | 9.59 % |
| Marzo | 6.76 % |
| Abril | 5.84 % |

## 6. Limpieza y diagnóstico de datos faltantes

La limpieza distingue entre faltantes explícitos y faltantes implícitos. Los primeros corresponden a celdas vacías o valores nulos dentro de los registros existentes. Los segundos representan combinaciones esperadas de centro asistencial y periodo que no aparecen en la base.

### 6.1. Faltantes explícitos

Se revisaron valores nulos y marcadores textuales de ausencia. El resultado reportado fue de 0.0 % de faltantes explícitos en las 14 variables.

**Tabla 5:** T03. Diagnóstico de faltantes explícitos

| Indicador | Resultado reportado |
|---|---|
| Valores nulos explícitos | 0 |
| Cadenas vacías o marcadores de ausencia | 0 |
| Porcentaje de faltantes explícitos | 0.0 % |
| Imputación por celdas vacías | No requerida |

## 6.2. Faltantes implícitos en el panel centro–mes

Para detectar meses sin reporte, se construyó un panel de periodos comprendidos entre el primer y el último registro de cada centro asistencial. Se identificaron 1,401 combinaciones centro–mes sin reporte (3.84 % de 36,443 esperados).

El diagnóstico muestra que 2020 presenta una tasa crítica de 11.63 % de meses sin reporte. En años regulares, la proporción se sitúa aproximadamente entre 2 % y 3 %.

**Tabla 6:** T04. Diagnóstico de faltantes implícitos

| Indicador | Resultado reportado |
|---|---|
| Tasa en años regulares | Aproximadamente 2 %–3 % |
| Tasa en 2020 | 11.63 % |
| Unidad examinada | Combinación centro asistencial–mes |
| Total casos | 1,401 casos (3.84 %) |

## 6.3. Consideración de los mecanismos MCAR, MAR y MNAR

El procedimiento utiliza tablas de contingencia y pruebas chi-cuadrado. Los resultados arrojaron un $\chi^2 = 940{,}10$ ($p < 0{,}001$) para el año y $\chi^2 = 359{,}54$ ($p < 0{,}001$) para la red. Esto indica que la ausencia depende de variables observadas, siendo compatible con un mecanismo MAR (Missing At Random). El mecanismo MNAR se reconoce como posible y se documenta como limitación.

## 6.4. Operaciones de limpieza

Las operaciones contempladas arrojaron los siguientes resultados:

- Duplicados eliminados: 0.
- Repeticiones de la clave (Año, mes, codcentro, codservicio): 0.
- Registros con `total` $\leq 0$ eliminados: 0.
- Normalización de departamentos: de 31 etiquetas a 25 departamentos.

- Nombres de vacuna: de 114 a 75 tras limpieza de tildes y mayúsculas.
- Registros finales: 614,465.

# 7. Imputación

No se requirió imputación directa de celdas vacías. Tampoco se completaron automáticamente los 1,401 meses sin reporte con valores cero, puesto que la ausencia de un registro no demuestra necesariamente que la demanda haya sido nula (posible MNAR). LazyPredict aplicó su imputación interna (media y categoría "missing") como resguardo para las variables de entrada.

# 8. Construcción de variables derivadas

Se generaron variables para facilitar la comparación entre tipos de vacuna y representar el contexto de la pandemia:

- `familia_vacuna`: agrupa las denominaciones en 14 familias. La vacuna contra la Influenza concentra el mayor volumen (25.23 %), seguida de Poliomielitis (12.92 %) y Neumococo (10.79 %).
- `covid`: indicador temporal que toma el valor 1 para 2020 y 2021.

**Tabla 7:** T05. Participación de las principales familias de vacuna

| Familia | Participación | Interpretación |
|---|---|---|
| Influenza | 25.23 % | Mayor participación; 4,648,309 dosis. |
| Poliomielitis | 12.92 % | Segunda familia por volumen. |
| Neumococo | 10.79 % | Tercera familia por volumen. |
| Hepatitis B | 10.01 % | Cuarta familia con mayor volumen. |

# 9. Análisis exploratorio de datos (EDA)

## 9.1. Distribución de la variable `total`

La variable original presenta una asimetría positiva pronunciada: media de 29.98, mediana de 9.0, asimetría de 25.74 y curtosis de 2141.9. Tras aplicar $\log(1 + \texttt{total})$, la asimetría se redujo a 0.497.

**Tabla 8:** T06. Estadísticos descriptivos de la variable `total`

| **Estadístico** | **Valor reportado** |
|---|---|
| Media | 29.98 |
| Mediana | 9.00 |
| Desviación estándar | 75.86 |
| Asimetría de `total` | 25.74 |
| Curtosis de `total` | 2141.91 |
| Asimetría de $\log(1 + \texttt{total})$ | 0.497 |
| % Atípicos (IQR) | 11.09 % |

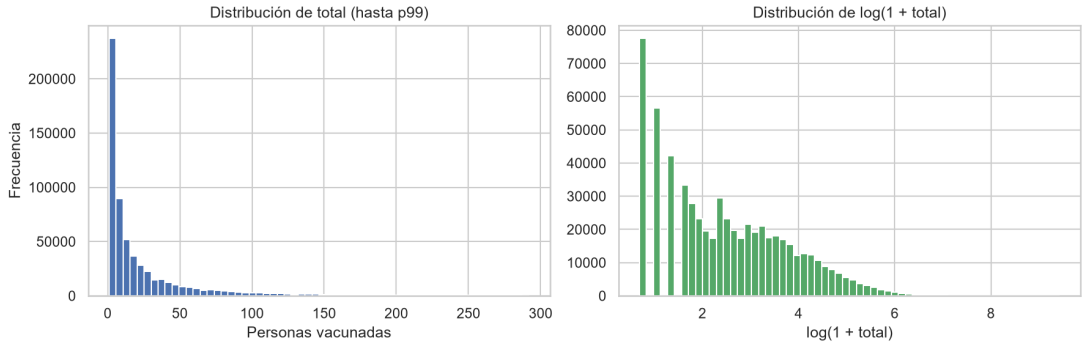



**Figura 1:** Distribución de `total` hasta el percentil 99 y distribución de $\log(1 + \texttt{total})$.

## 9.2. Evolución anual y estacionalidad mensual

El gráfico G02 presenta la evolución anual de las dosis y el promedio mensual. Se observa la caída en 2020–2021 y la recuperación en 2022, así como la estacionalidad mensual.

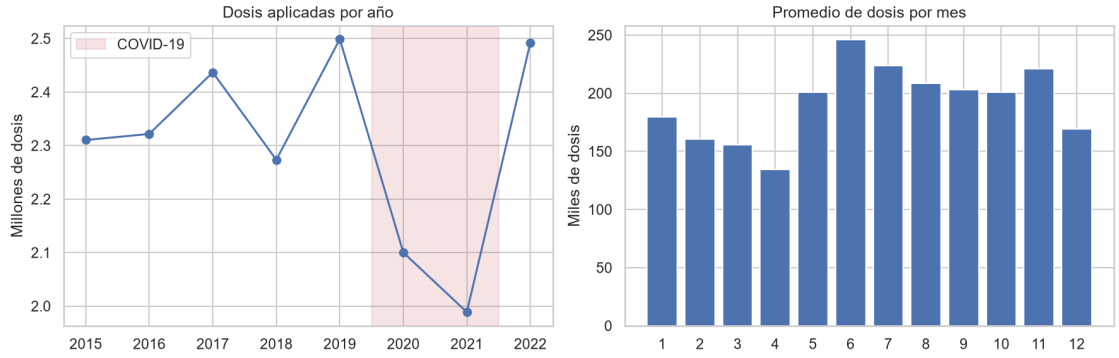



**Figura 2:** Dosis aplicadas por año y promedio de dosis por mes.

## 9.3. Distribución conjunta por año y mes

El mapa de calor G03 detalla el volumen mensual. Se destacan la reducción en abril de 2020 (22 mil dosis) y el pico en noviembre de 2020 (430 mil dosis).

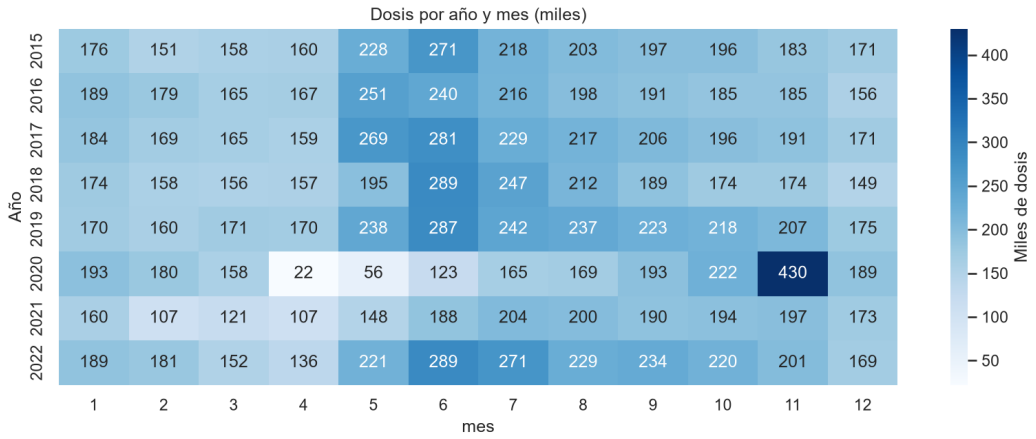



**Figura 3:** Dosis por año y mes, expresadas en miles.

## 9.4. Dosis por familia de vacuna y red prestacional

El gráfico G04 compara el volumen por familia y las 12 redes con mayor cantidad de dosis. Sabogal, Rebagliati y Almenara son las de mayor volumen.

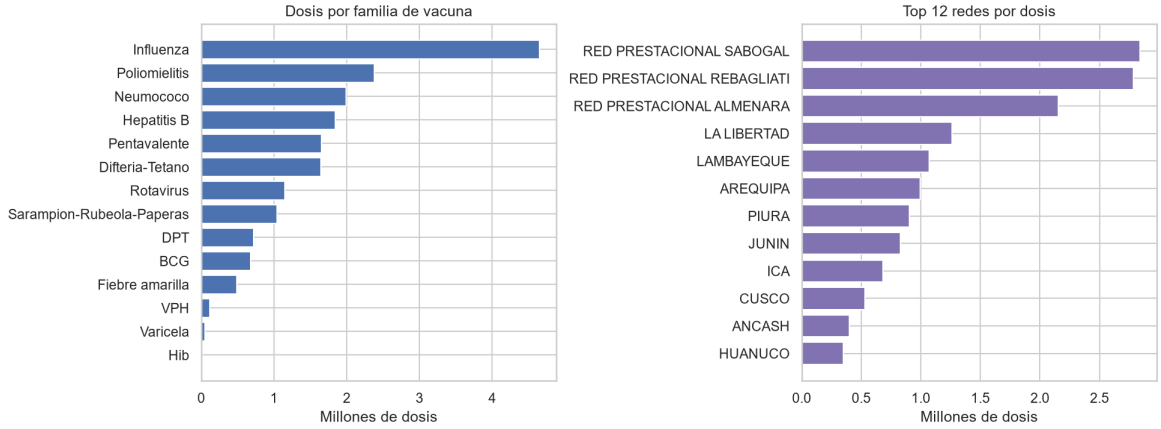



**Figura 4:** Dosis acumuladas por familia de vacuna y principales redes prestacionales.

## 9.5. Distribución de la demanda por familia

El gráfico G05 compara la distribución de $\log(1 + \texttt{total})$ entre familias mediante diagramas de caja.

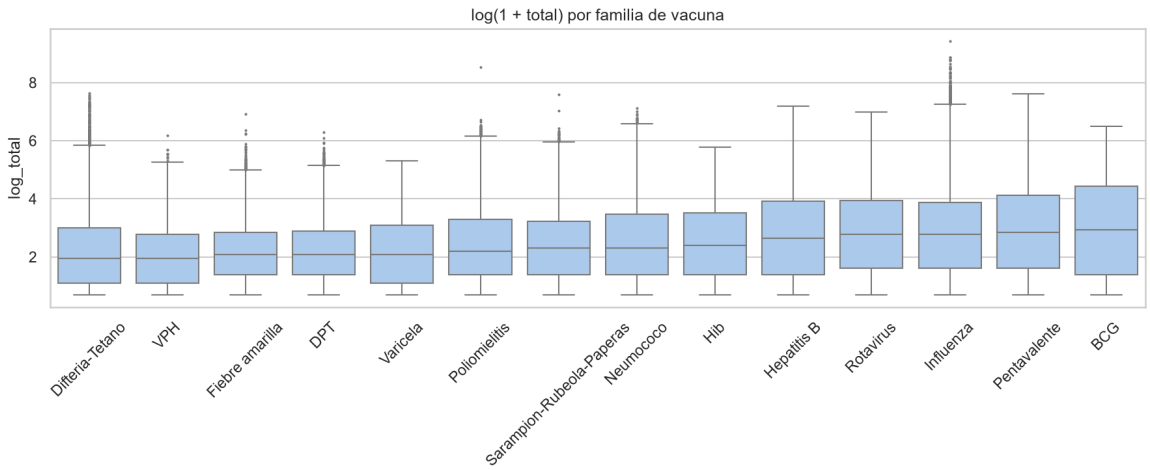



**Figura 5:** Distribución de $\log(1 + \texttt{total})$ por familia de vacuna.

## 9.6. Comparación entre Puno y el resto del país

Puno presenta una media de 14.16 y mediana de 4.0, muy inferiores al resto del país (media 30.81, mediana 10.0).

**Tabla 9:** T07. Comparación descriptiva entre Puno y el resto del país

| Indicador | Puno | Resto del país |
|---|---|---|
| Registros | 30,607 | 583,858 |
| Dosis | 433,441 | 17,988,275 |
| Media de dosis por registro | 14.16 | 30.81 |
| Mediana de dosis por registro | 4.00 | 10.00 |

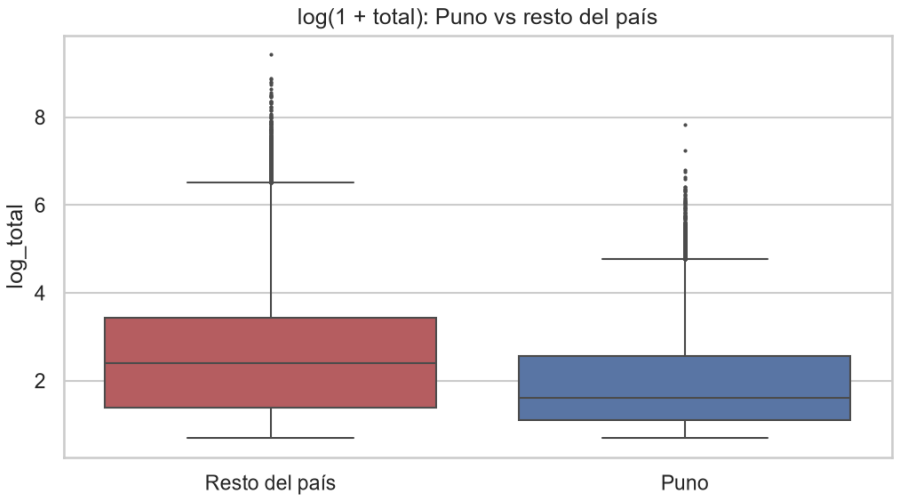



**Figura 6:** Comparación de $\log(1 + \texttt{total})$ entre Puno y el resto del país.

### 9.7. Asociación Eta cuadrado entre predictoras y demanda

El centro asistencial presenta el valor más elevado (0.4478), seguido de la red prestacional (0.1260). Las variables temporales y COVID son marginales.

**Tabla 10:** T08. Asociación Eta cuadrado con `log_total`

| Predictora | Eta cuadrado reportado |
|---|---|
| Centro asistencial (`codcentro_ses`) | 0.4478 |
| Red prestacional (`red_ses`) | 0.1260 |
| Familia de vacuna | 0.0461 |
| Año | 0.0136 |
| COVID-19 | 0.0028 |
| Mes | 0.0010 |

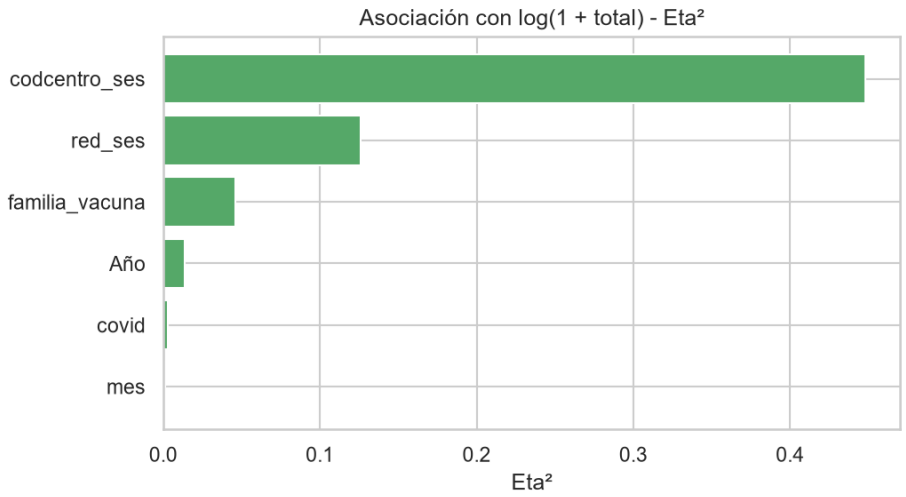



**Figura 7:** Asociación de las variables predictoras con $\log(1 + \texttt{total})$ mediante Eta cuadrado.

## 10. Definición de las variables objetivo

### 10.1. Variable objetivo de regresión

La variable objetivo es $y_{\text{reg}} = \log(1 + \texttt{total})$.

### 10.2. Variable objetivo de clasificación

Para clasificación, la variable `total` se discretizó en tres categorías mediante terciles: Baja ($\leq 4$), Media (5–20) y Alta ($\geq 21$).

**Tabla 11:** T09. Distribución de la variable `nivel_demanda`

| Categoría | Registros | Porcentaje |
|---|---|---|
| Baja | 209,733 | 34.13 % |
| Media | 206,015 | 33.53 % |
| Alta | 198,717 | 32.34 % |

Las proporciones son cercanas, por lo que las clases pueden describirse como aproximadamente balanceadas.

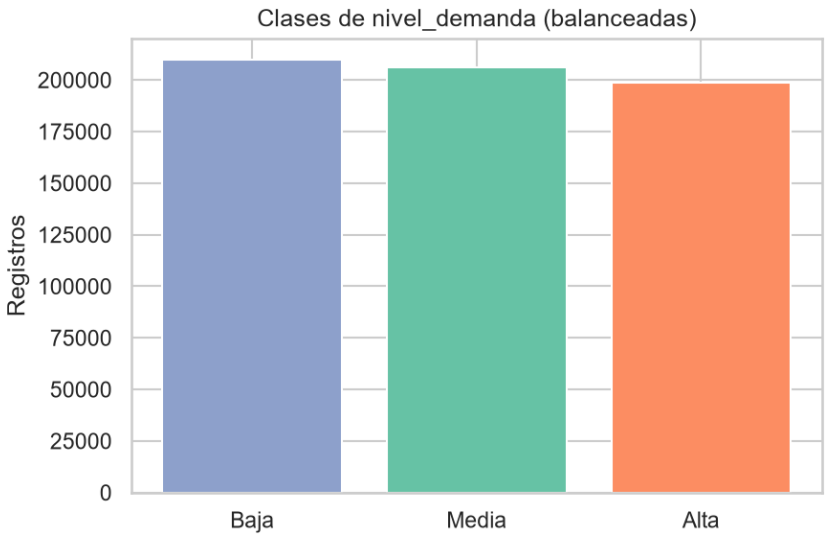



**Figura 8:** Distribución de registros por nivel de demanda.

## 11. Diseño de modelado y partición de datos

Se seleccionó una muestra estratificada de 30,002 registros (4.88 % de la población), con semilla 42. La prueba Kolmogorov–Smirnov arrojó $D = 0{,}0032$ y $p = 0{,}9351$, confirmando que la muestra representa a la población.

La partición fue de 24,001 registros para entrenamiento (80 %) y 6,001 para prueba (20 %). La validación geográfica en Puno utilizó 29,104 registros fuera de la muestra.

**Tabla 12:** Configuración de muestreo y partición

| Elemento | Configuración reportada |
|---|---|
| Tamaño de muestra | 30,002 registros |
| Semilla aleatoria | 42 |
| Prueba Kolmogorov–Smirnov | $D = 0{,}0032, p = 0{,}9351$ |
| Entrenamiento | 24,001 registros |
| Prueba | 6,001 registros |
| Validación Puno | 29,104 registros |

# 12. Modelado con LazyPredict

## 12.1. Comparación de modelos de regresión

XGBRegressor obtuvo el mejor resultado, con $R^2 = 0{,}5021$, $R^2$ ajustado de 0.4982 y RMSE de 0.9340. HistGradientBoosting y LGBM le siguen en rendimiento.

**Tabla 13:** T10. Resumen de resultados de LazyRegressor (Top 4)

| Modelo | R² Ajustado | R² | RMSE |
|---|---|---|---|
| XGBRegressor | 0.4982 | 0.5021 | 0.9340 |
| HistGradientBoosting | 0.4731 | 0.4772 | 0.9571 |
| LGBMRegressor | 0.4719 | 0.4760 | 0.9582 |
| RandomForestRegressor | 0.4712 | 0.4753 | 0.9588 |

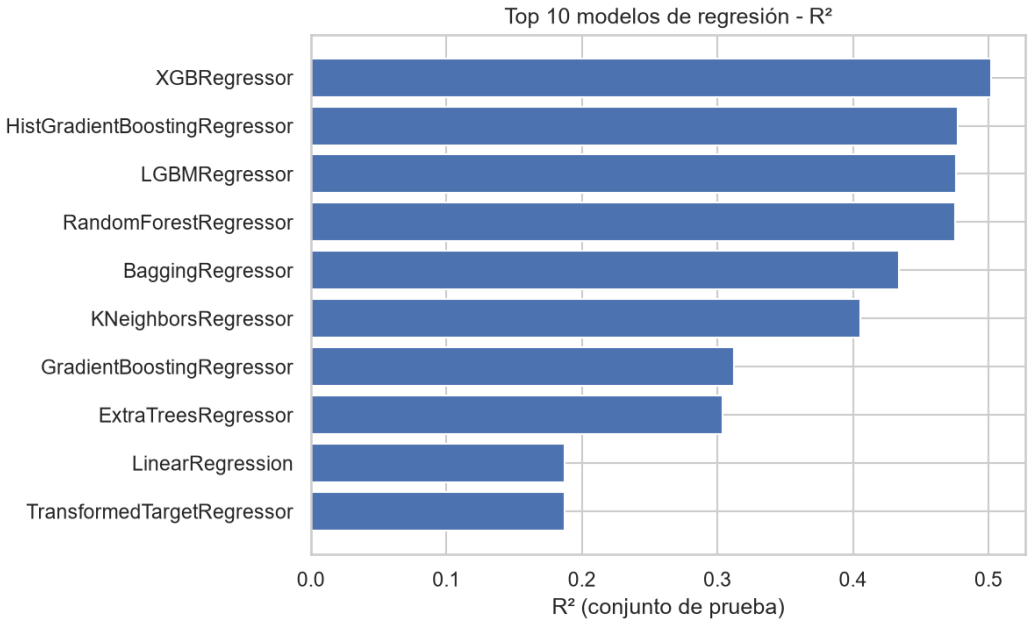



**Figura 9:** Los diez modelos de regresión con mejor resultado según LazyPredict.

## 12.2. Comparación de modelos de clasificación

LGBMClassifier alcanzó el mejor Balanced Accuracy (0.6218) y F1-Score (0.6162).

**Tabla 14:** T11. Resumen de resultados de LazyClassifier (Top 4)

| Modelo | Accuracy | Bal. Accuracy | F1-Score |
|---|---|---|---|
| LGBMClassifier | 0.6204 | 0.6218 | 0.6162 |
| BaggingClassifier | 0.6002 | 0.6015 | 0.5959 |
| KNeighborsClassifier | 0.5869 | 0.5888 | 0.5785 |
| DecisionTreeClassifier | 0.5582 | 0.5592 | 0.5574 |

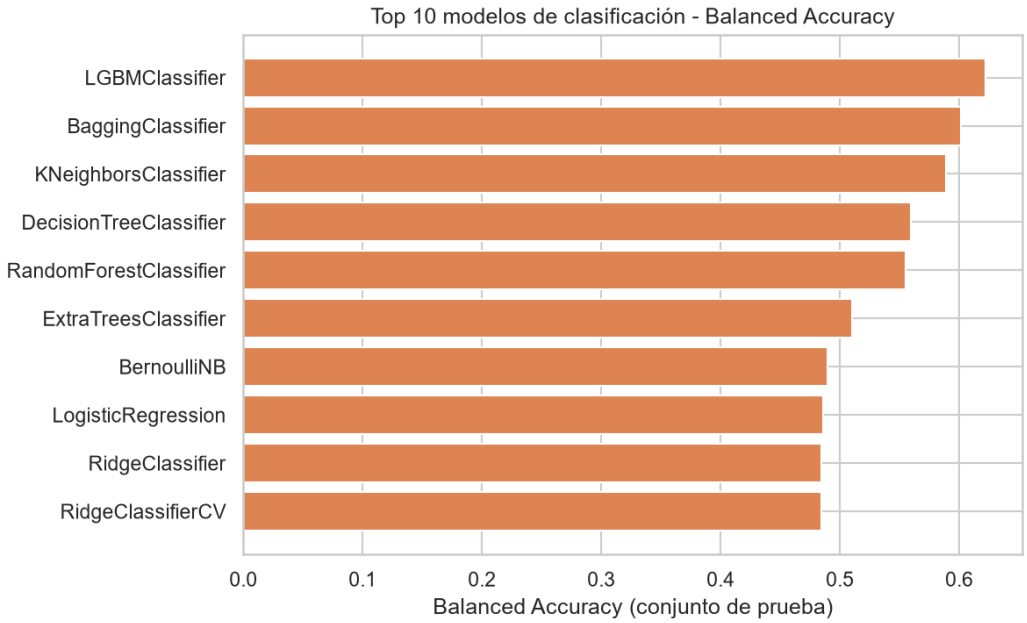



**Figura 10:** Los diez modelos de clasificación con mejor Balanced Accuracy.

# 13. Evaluación y validación de los modelos seleccionados

## 13.1. Validación del modelo de regresión (XGBRegressor)

El $R^2$ fue 0.5021 en prueba nacional y 0.4818 en Puno. El MAE en Puno fue de 9.30 (menor que el nacional de 19.84 debido al menor volumen de dosis en esa región).

**Tabla 15:** T12. Validación del modelo de regresión

| Métrica | Prueba nacional | Validación Puno |
|---|---|---|
| $R^2$ (log) | 0.5021 | 0.4818 |
| RMSE (log) | 0.9340 | 0.7965 |
| MAE (personas) | 19.8369 | 9.3016 |
| Mediana error abs. | 5.6325 | 2.6886 |

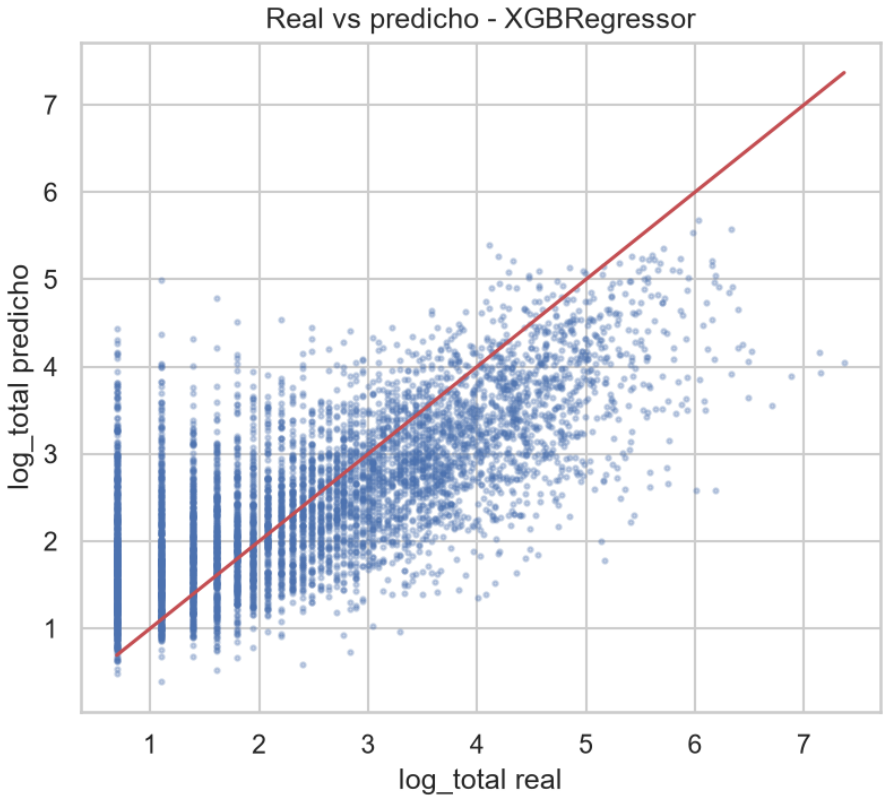



**Figura 11:** Valores reales frente a valores predichos por XGBRegressor.

## 13.2. Validación del modelo de clasificación (LGBMClassifier)

La Accuracy fue 0.6204 en nacional y 0.6332 en Puno. El Balanced Accuracy disminuyó de 0.6218 a 0.5772. El reporte por clase muestra que la categoría "Media.es la más difícil de predecir (F1 = 0.493), mientras que .Alta"tiene el mejor desempeño (F1 = 0.717).

**Tabla 16:** T13. Validación del modelo de clasificación

| Métrica | Prueba nacional | Validación Puno |
|---|---|---|
| Accuracy | 0.6204 | 0.6332 |
| Balanced Accuracy | 0.6218 | 0.5772 |
| F1 ponderado | 0.6162 | 0.5966 |

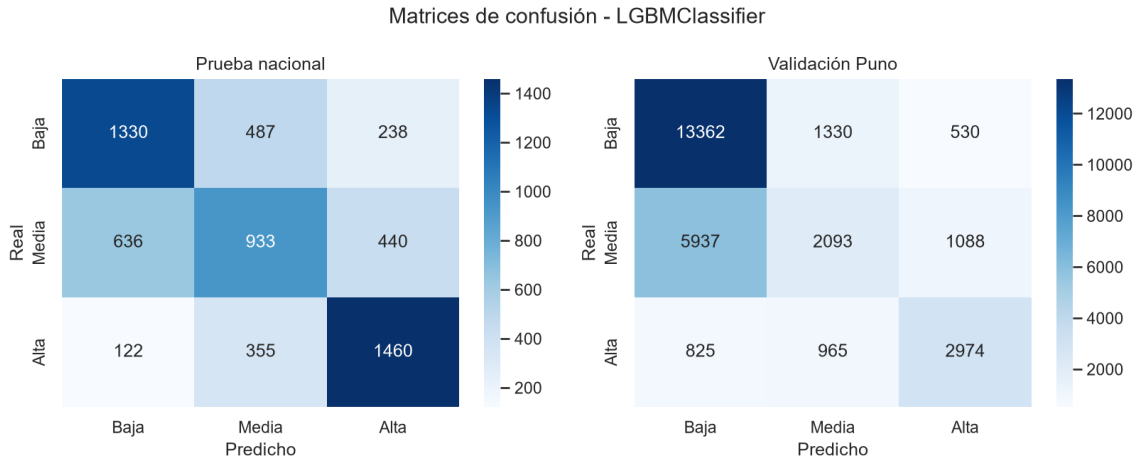



**Figura 12:** Matrices de confusión de LGBMClassifier para la prueba nacional y la validación geográfica en Puno.

## 13.3. Importancia de variables mediante permutación

El centro asistencial y la red prestacional son las variables más importantes.

**Tabla 17:** T14. Importancia de variables por permutación

| **Variable** | **Caída de $R^2$** |
|---|---|
| `codcentro_ses` | 0.5923 |
| `red_ses` | 0.5233 |
| `familia_vacuna` | 0.1601 |
| Año | 0.0805 |
| Mes | 0.0231 |
| COVID | 0.0013 |

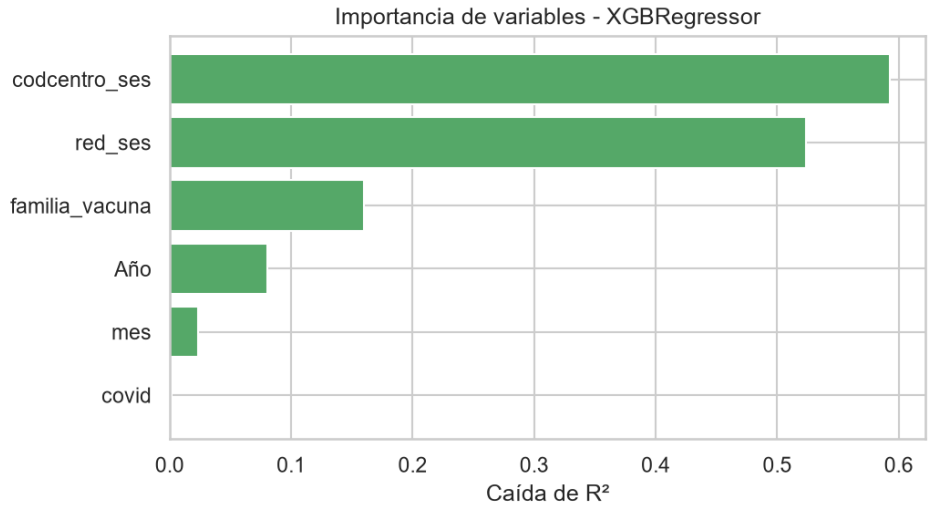



**Figura 13:** Importancia de las variables predictoras mediante permutación en XGBRegressor.

## 14. Discusión de resultados

Los resultados muestran que la demanda de inmunizaciones presenta una distribución altamente asimétrica y heterogénea. Los métodos basados en árboles y ensambles superan a los modelos lineales. XGBRegressor obtuvo el mejor desempeño para regresión y LGBMClassifier para clasificación.

La importancia de las variables confirma que la ubicación institucional (centro y red) aporta la mayor información predictiva. En la validación de Puno, XGBRegressor conservó un $R^2$ cercano al nacional. Sin embargo, en clasificación, aunque la Accuracy mejoró ligeramente en Puno, el Balanced Accuracy disminuyó, lo que indica un comportamiento desigual entre clases en esa región.

## 15. Limitaciones del estudio

1. Los registros administrativos no permiten distinguir entre ausencia de aplicación y ausencia de reporte.
2. La definición de faltantes implícitos depende del panel temporal construido.
3. La clasificación en terciles simplifica una variable continua.
4. La validación de Puno es geográfica, pero usa la misma fuente de datos.
5. La elevada importancia de los códigos de centro puede reflejar patrones propios de los establecimientos observados.
6. LazyPredict es una comparación inicial y no sustituye una optimización exhaustiva de hiperparámetros.

## 16. Conclusiones

1. La base de datos cuenta con 614,465 registros (2015–2022) y 18,421,716 dosis totales.
2. No se identificaron faltantes explícitos, pero sí 1,401 faltantes implícitos (3.84 %), con un pico del 11.63 % en 2020 (mecanismo MAR).
3. La transformación $\log(1 + \texttt{total})$ redujo la asimetría de 25.74 a 0.497.
4. La vacuna contra la Influenza concentra la mayor participación (25.23 %).
5. Para regresión, XGBRegressor obtuvo $R^2 = 0{,}5021$ y RMSE=0.9340. Para clasificación, LGBMClassifier alcanzó un Balanced Accuracy de 0.6218.
6. En Puno, XGBRegressor obtuvo $R^2 = 0{,}4818$. En clasificación, el Balanced Accuracy disminuyó a 0.5772, evidenciando que la categoría "Media.$^{\text{es}}$ la más difícil de predecir.
7. El centro asistencial y la red prestacional fueron las variables con mayor importancia predictiva.

## 17. Recomendaciones

1. Verificar los registros sin reporte con la entidad fuente.
2. Conservar los registros con valor cero cuando representen ausencia real de aplicación.
3. Evaluar los modelos mediante particiones temporales y validación agrupada por centro.
4. Examinar las métricas por familia de vacuna y red.
5. Optimizar hiperparámetros de XGBRegressor y LGBMClassifier.
6. Revisar especialmente el recall de la categoría "Media.[en] clasificación.
7. Mantener actualizado el conjunto de datos para reentrenar los modelos.

## 18. Repositorio y reproducibilidad

El código fuente y los archivos generados se encuentran organizados en un repositorio de GitHub.

**Enlace del repositorio:** https://github.com/austraraptor/resultados_lazypredict.git

## Anexo: relación de productos gráficos

Los 13 archivos PNG deben subirse al mismo directorio del archivo `.tex`:

**Tabla 18:** Relación de gráficos generados por el análisis

| Código | Nombre del archivo | Contenido |
|---|---|---|
| G01 | `G01_distribucion_total.png` | Distribución original y transformada. |
| G02 | `G02_anual_y_estacionalidad.png` | Evolución anual y patrón mensual. |
| G03 | `G03_calor_anio_mes.png` | Mapa de calor por año y mes. |
| G04 | `G04_familias_y_redes.png` | Familias de vacuna y principales redes. |
| G05 | `G05_boxplot_familias.png` | Distribución por familia. |
| G06 | `G06_puno_vs_resto.png` | Comparación Puno vs resto. |
| G07 | `G07_eta2_predictoras.png` | Asociación Eta cuadrado. |
| G08 | `G08_clases_nivel_demanda.png` | Distribución de clases. |
| G09 | `G09_top10_regresion.png` | Ranking de regresión. |
| G10 | `G10_top10_clasificacion.png` | Ranking de clasificación. |
| G11 | `G11_real_vs_predicho.png` | Reales vs predichos. |
| G12 | `G12_matrices_confusion.png` | Matrices de confusión. |

| Código | Nombre del archivo | Contenido |
|---|---|---|
| G13 | `G13_importancia_variables.png` | Importancia por permutación. |